


VERİ MADENCİLİĞİ DÖNEM ÖDEVİ

Konu: Telco Müşteri Kaybı (Churn) Analizi ve Tahminleme Araç: Orange Data Mining Tool

KISIM 1 Veriyi Tanıma ve Hazırlama (Preprocessing & EDA)

Workflows:


1W) Veri Yükleme: Telco Customer Churn Dataset



The image shows a workflow in the Orange Data Mining Tool. It consists of two widgets: 'Datasets' and 'Data Table', connected by a 'Data' link. Below the workflow, the 'Data Table - Orange' window is open, displaying the Telco Customer Churn dataset. The window has a menu bar (File, Edit, View, Window, Help) and a sidebar with 'Info', 'Variables', and 'Selection' sections. The main area shows a table with columns: Churn, customerID, gender, and SeniorCitizen. The table contains 7043 rows of data. The 'Info' section shows: 7043 instances, 19 features (0.0 % missing data), Target with 2 values, and 1 meta attribute. The 'Variables' section has checkboxes for 'Show variable labels (if present)', 'Visualize numeric values', and 'Color by instance classes'. The 'Selection' section has a 'Clear Selection' button and a 'Select full rows' checkbox. The 'Send Automatically' checkbox is also checked. The status bar at the bottom shows 7043 instances and 7043 features.

Churn	customerID	gender	SeniorCitizen
No	7969-FFOWG	Male	0
No	4718-DHSMV	Female	0
No	5175-WLYXL	Male	0
No	7817-OMJNA	Male	0
No	8728-SKJLR	Male	0
No	3137-NYQQI	Male	0
No	7706-DZNNK	Male	0
Yes	0236-HFWSV	Male	0
Yes	3900-AQPHZ	Female	0
Yes	5842-POCOP	Female	0
Yes	2037-XJFUP	Male	0
No	8823-RLPWL	Female	0
No	9505-SQFSW	Female	0
Yes	7314-OXENN	Male	0
No	3758-CKOQL	Female	0
Yes	0322-CHQRU	Male	0
No	5676-CFLYY	Male	0
No	7521-AFHAB	Female	0
No	0285-INHLN	Male	0
Yes	4678-DVQEO	Female	0
No	5125-CNDSP	Male	0

2W) Veri Denetimi: TotalCharges sütunundaki sayısal değerlerin neden "text" olarak algılandığını tespiti.



TotalCharges
?
?
?
?
?
?
?
?
?
?
8684.80
8672.45
8670.10
8594.40
8564.75

Görselde görüldüğü üzere TotalCharges sütununda bazı alanlar “ ? ” olarak işaretlenmiş. Bunun sebebi temel olarak 3 sebepten kaynaklanıyor olabilir.

1. **Görünmez Boşluklar (Blank Spaces):** Bu veri setinde bazı satırlarda TotalCharges değeri girilmemiştir. Ancak bu hücreler "NULL" veya "NaN" (boş) olarak değil, klavyeden basılmış bir **boşluk karakteri (" ")** olarak duruyor olabilir.
2. **Sistem Mantığı:** Orange sütunu tararken sayıları görür, ancak o tek bir boşluk karakterine rastladığında bu sütun sadece sayılardan değil aynı zamanda metin karakterlerinden -boşluk- oluşuyor ve o satırları metin olarak tanımlıyor olabilir.
3. **Hatalı Girişler:** Bazen binlik ayırıcı olarak kullanılan virgül (,) veya yanlışlıkla girilmiş bir nokta (.) da Orange'ın kafasını karıştırıp veri tipini metne çevirmesine neden olur.

Çözüm Yolu:

- **Edit Domain** widget'ı kullanılır.
- TotalCharges sütununu seçip tipini **Numeric** yapılır.
- Bunu yaptığında o boşluk karakterleri artık **NaN** (Not a Number - Tanımsız Değer) haline gelecektir.
- İşte bu noktadan sonra istenilen **Impute** widget'ı devreye girecek ve o "tanımsız" hale getirdiğimiz boşlukları ortalamayla dolduracaktır.


3W) Temizlik (Preprocess):

- **Impute widget'ı ile boş (NaN) değerleri ortalama (mean) ile doldurma.**


Veri setindeki TotalCharges sütunu, içerisinde sayısal olmayan karakterler (boşluklar) barındırdığı için başlangıçta Text (String) veri tipinde algılanmıştır.

Column Statistics widget'i üzerinden yapılan incelemede, bu sütunda 'Missing Values' (Eksik Değerler) olduğu tespit edilmiştir.

Orange içerisinde bu eksik veriler '?' sembolü ile gösterilmektedir. Bu durum, verinin matematiksel modellemeye girmesine engel olduğu için öncelikle veri tipi Numeric olarak zorlanmış, ardından eksik değerler Impute yöntemiyle doldurulmak üzere hazırlanmıştır.




Impute işleminden sonra veri setinin ve Null alanların durumu:




- **Select Columns ile tahminleme için anlamsız olan customerID sütununu devre dışı bırakılması.**

Modelin başarısını artırmak ve algoritmaların yanıltıcı çıkarımlar yapmasını önlemek amacıyla Select Columns widget'ı kullanılmıştır. **customerID** sütunu, her müşteri için benzersiz bir değer içerdiğinden ve müşterinin terk etme (churn) eğilimi üzerinde istatistiksel olarak anlamlı bir etkisi bulunmadığından analiz dışı bırakılmıştır (Ignore).



4W) Görsel Analiz (EDA):

- **Distributions widget'ını kullanarak: "Sözleşme tipi (Contract)" ile "Ayrılma (Churn)" arasındaki ilişkiyi gösteren grafiği oluşturulması.**




Grafik incelendiğinde, sözleşme süresi ile müşteri kaybı arasında ters bir orantı olduğu açıkça görülmektedir. Month-to-month (aylık) sözleşmeye sahip müşterilerde kırmızı (churn) yoğunluğu en yüksek seviyededir; bu grup şirketin en riskli müşteri profilini oluşturmaktadır. Buna karşılık, Two year (iki yıllık) sözleşme yapan müşterilerde kayıp oranı %2.83 gibi ihmal edilebilir bir seviyeye düşmektedir. Bu durum, uzun vadeli sözleşmelerin müşteri bağlılığını (retention) doğrudan artırdığını kanıtlamaktadır.

Bu grafik sonucunda elde edilebilecek, ön görülebilecek sonuçlar ve kritik noktalar şunlardır.

- ➔ **Risk Grubu (Month-to-Month):** En soldaki sütuna bakıldığında, mavi ve kırmızı boyları birbirine oldukça yakın. Yani her ay yeni gelen müşterilerin neredeyse yarısına yakını gitme eğiliminde. Operasyonel maliyet burada çok yüksek.
- ➔ **Güvenli Liman (Two Year):** En sağdaki kutucuğun üzerine geldiğinde çıkan değerlere bakıldığında: **Yes: 48**. Toplam 1695 kişiden sadece 48'i gitmiş. Yani bir müşteri 2 yıllık sözleşmeye ikna edildiğinde, onu %97 ihtimalle tutuyor olduğumuz görülüyor.

- **Scatter Plot kullanarak: "Aylık Ödeme (MonthlyCharges)" ve "Müşteri Sadakati (Tenure)" arasındaki ilişkiyi Churn bazlı renklendirerek analiz edilmesi.**




Scatter Plot grafiği incelendiğinde, müşteri kaybının (Churn=Yes) özellikle düşük sadakat süresi (tenure < 20 ay) ve yüksek aylık ödeme (MonthlyCharges > 70) bölgesinde yoğunlaştığı görülmektedir. Bu durum, yüksek ücret ödeyen yeni müşterilerin şirketi terk etme eğiliminin en fazla olduğu 'kritik risk bölgesini' temsil eder. Öte yandan, grafik sağa doğru ilerledikçe (sadakat süresi arttıkça), yüksek ücret ödense dahi mavi noktaların (kalan müşteriler) baskın olduğu, yani müşteri sadakatinin yüksek maliyet etkisini kırdığı gözlemlenmiştir.

1. **En Riskli Bölge (Sol Üst Köşe):** Grafiğin sol üstüne bak, kırmızılar orada kümelenmiş. Bu şu demek: "Adam daha yeni gelmiş, ona yüksek fatura kesmişiz ve adam anında kaçmış."
2. **Sadakat Filtresi (Sağ Taraf):** Sağ tarafa gittikçe kırmızılar seyreliyor. Demek ki müşteri ilk 20-30 ayı kazasız belasız atlatırsa, faturası yüksek olsa bile gitme ihtimali azalıyor.
3. **Ekonomik Ayrım (Alt Bant):** Grafiğin en altında, 20 birim civarında yatay bir mavi çizgi görülüyor. Bunlar muhtemelen en ucuz paketi kullanan ve kolay kolay gitmeyen, "düşük maliyetli-sadık" kitle.

Teslim Edilecekler:


1) Orange Workflow (Akış Şeması) ekran görüntüsü:



2) En çok hangi sözleşme tipindeki müşterilerin terk ettiğine dair 2 cümlelik teknik yorum.

Yapılan dağılım analizi sonucunda, en yüksek müşteri kaybının (churn) Month-to-month (Aylık) sözleşme tipine sahip grupta gerçekleştiği, bu gruptaki terk oranının uzun vadeli sözleşmelere oranla kritik düzeyde yüksek olduğu gözlemlenmiştir. Bu durum, finansal taahhüdün düşük olduğu esnek sözleşme modellerinin müşteri sadakatini (retention) zayıflattığını ve operasyonel riskin ana kaynağını oluşturduğunu teknik olarak kanıtlamaktadır.

3) Temizlenmiş verinin Data Table üzerindeki son hali:




	Churn	gender	SeniorCitizen	Partner	Dependents	tenure	PhoneService	MultipleLines	InternetSer
1	No	Female	0	Yes	No	1	No	No phone service	DSL
2	No	Male	0	No	No	34	Yes	No	DSL
3	Yes	Male	0	No	No	2	Yes	No	DSL
4	No	Male	0	No	No	45	No	No phone service	DSL
5	Yes	Female	0	No	No	2	Yes	No	Fiber optic
6	Yes	Female	0	No	No	8	Yes	Yes	Fiber optic
7	No	Male	0	No	Yes	22	Yes	Yes	Fiber optic
8	No	Female	0	No	No	10	No	No phone service	DSL
9	Yes	Female	0	Yes	No	28	Yes	Yes	Fiber optic
10	No	Male	0	No	Yes	62	Yes	No	DSL
11	No	Male	0	Yes	Yes	13	Yes	No	DSL
12	No	Male	0	No	No	16	Yes	No	No
13	No	Male	0	Yes	No	58	Yes	Yes	Fiber optic
14	Yes	Male	0	No	No	49	Yes	Yes	Fiber optic
15	No	Male	0	No	No	25	Yes	No	Fiber optic
16	No	Female	0	Yes	Yes	69	Yes	Yes	Fiber optic
17	No	Female	0	No	No	52	Yes	No	No
18	No	Male	0	No	Yes	71	Yes	Yes	Fiber optic
19	Yes	Female	0	Yes	Yes	10	Yes	No	DSL
20	No	Female	0	No	No	21	Yes	No	Fiber optic
21	Yes	Male	1	No	No	1	No	No phone service	DSL
22	No	Male	0	Yes	No	12	Yes	No	No
23	Yes	Male	0	No	No	1	Yes	No	No
24	No	Female	0	Yes	No	58	Yes	Yes	DSL
25	No	Male	0	Yes	Yes	49	Yes	No	DSL
26	No	Female	0	No	No	30	Yes	No	DSL
27	Yes	Male	0	Yes	Yes	47	Yes	Yes	Fiber optic
28	Yes	Male	0	Yes	Yes	1	No	No phone service	DSL
29	No	Male	0	Yes	No	72	Yes	Yes	DSL
30	Yes	Female	0	No	Yes	17	Yes	No	DSL
31	No	Female	1	Yes	No	71	Yes	Yes	Fiber optic
32	No	Male	1	Yes	No	2	Yes	No	Fiber optic
33	No	Female	0	Yes	Yes	27	Yes	No	DSL

KISIM 2 Tahminleme ve Model Değerlendirme (Modeling & Evaluation)


Workflows:

1. Veri Ayırma: Data Sampler widget'ını kullanarak veriyi %80 Eğitim (Training) ve %20 Test (Testing) olarak ikiye böldü.



2. **Model Kurma:** Veriyi aynı anda şu üç farklı algoritmaya bağlandı:

1. Logistic Regression
2. Decision Tree (Karar Ağacı)
3. Random Forest



3. Performans Ölçümü: Modeller Test And Score widget'ına bağlandı. "AUC" ve "Classification Accuracy" değerleri karşılaştırıldı.

Bu aşamada istenilen “AUC” ve “Classification Accuracy” değerleri:

1. Classification Accuracy (CA) - Sınıflandırma Doğruluğu

"Model ne kadar bildi?"

- Modelin yaptığı toplam tahminler içinde, doğru tahmin edilenlerin (hem kalanların hem de gidenlerin toplam doğru sayısı) tüm veri setine oranıdır.
- Modelim, sisteme giren her 100 müşteriden 81 tanesinin Churn (terk) durumunu doğru tahmin etmiştir.

2. AUC (Area Under ROC Curve) - Ayırt Etme Gücü

"Modelin Churn olanla olmayanı birbirinden ne kadar net ayırdığına"

- Modelin, rastgele seçilen bir "Churn (Gidecek)" müşteriye, rastgele seçilen bir "Stay (Kalacak)" müşteriden daha yüksek bir risk puanı verme olasılığıdır.
- **Değer Aralığı:**
 - **0.5:** Model hiçbir şey ayırt edemiyor.
 - **0.7 - 0.8:** Kabul edilebilir.
 - **0.8 - 0.9:** Çok iyi.
 - **1.0:** Mükemmel.
- "Doğruluk (CA) bazen yanıltıcı olabilir (örneğin herkes kalıyor dersiniz de doğruluk yüksek çıkabilir), ancak AUC modelimizin 'gerçekten giden' müşteriye 'kalacak olan' müşteriden ayırma konusunda %84.3 oranında bir yeteneğe sahip olduğunu kanıtlıyor."

Bu açıklamalardan sonrasında elde edilen sonuçlar:

- **Yöntem:** Modellerin gerçek performansını ölçmek için Data Sampler ile ayrılan %20'lik "hiç görülmemiş" veri seti kullanılmıştır.
- **İşlem:** Test and Score widget'ı içerisinde "**Test on test data**" seçeneği işaretlenerek, modellerin eğitim verisindeki ezber yeteneği değil, yeni verideki tahmin başarısı ölçülmüştür.
- **Karşılaştırma:** Elde edilen **AUC** (Modelin sınıfları birbirinden ayırma başarısı) ve **CA** (Doğru tahmin oranı) değerleri üzerinden modeller yarışmaya sokulmuştur.

Test and Score - Orange

File Edit View Window Help

☐ Cross validation
Number of folds: 5
☒ Stratified
☐ Cross validation by feature
☐ Random sampling
Repeat train/test: 10
Training set size: 66 %
☒ Stratified
☐ Leave one out
☐ Test on train data
☒ Test on test data

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
Logistic Regression	0.843	0.812	0.805	0.802	0.812	0.463
Tree	0.651	0.760	0.755	0.751	0.760	0.330
Random Forest	0.796	0.786	0.778	0.774	0.786	0.387

Compare models by: Area under ROC curve ☐ Negligible diff.: 0.1

	Logistic Regression	Tree	Random Forest
Logistic Regression			
Tree			
Random Forest			

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

5776 | 1267 | 1267 | 3x1267

Logistic Regression modelimiz hem yüksek CA (0.812) hem de yüksek AUC (0.843) değerlerine sahip olduğu için, sadece yüksek bir doğru tahmin oranı sunmakla kalmıyor, aynı zamanda riskli ve sadık müşterileri birbirinden ayırma konusunda da en yüksek güvenilirliği sağlıyor.

4. **Hata Analizi:** En iyi çalışan model için Confusion Matrix (Karmaşıklık Matrisi) oluşturun. Kaç müşterinin "ayrılacak" denmesine rağmen "kaldığını" (False Positive) bulun.


False Positive Nedir?

En basit tanımıyla: **"Gerçekte olmayan bir durumun, model tarafından varmış gibi tahmin edilmesidir."**

Telco (Müşteri Kaybı) senaryona uyarlarsak:

- **Gerçek durum (Actual):** Müşteri aslında çok mutlu ve şirketinizden ayrılmaya hiç niyeti yok (**Churn = No**).
- **Modelin Tahmini (Predicted):** Kurulan yapay zeka modeli bu müşterinin verilerine bakıyor ve "Bu müşteri kesin kaçacak!" diyor (**Churn = Yes**).

Sonuç: Modelin "Yanlış" (False) bir "Pozitif" (Pozitif burada 'olay gerçekleşecek' yani 'Churn olacak' anlamındadır) alarm verdi.



False Positive Sayısı: 87

Teknik Yorum: "Modelimiz, aslında şirketten ayrılmayacak olan (Actual: No) **87** müşteriyi hatalı bir şekilde 'ayrılacak' (Predicted: Yes) olarak tahmin etmiştir. Bu durum, bu 87 müşteri için yapılacak olan geri kazanma kampanyalarının (indirim, hediye vb.) gereksiz bir maliyet oluşturacağını göstermektedir."

False positive verileri bulma konusunda model **Overfitting** yapıyor. İstenilen sonucu elde etmek için:


1. Ağacı Budama: Karar ağaçları, siz onları durdurmazsanız verideki en küçük detayı, hatta tesadüfi hataları (gürültüyü) bile ezberlemeye çalışır. Bu da Tree Viewer sonuçlarında gördüğümüz o devasa, karmaşık ve okunmaz yapıya sebep olur. Budama işlemi; ağacın çok derinlere dallanmasını engelleyerek, modelin sadece **en önemli** ve **genellenebilir** kuralları öğrenmesini sağlar. Bunun için:

Tree widget'indeki Limit Maximal Tree Depth değeri 3'e çekildi.


Bu ayar, ağaca şu emri verir: *"En tepeden başla ama asla 3 kattan fazla aşağı inme!"*

- **Derinlik (Depth) = 0:** Sadece ana gövde (hiç karar yok).
- **Derinlik = 1:** En önemli soruyu sor (Örn: Sözleşme tipi?).
- **Derinlik = 3:** En önemli 3 seviyeli soru dizisini tamamla ve orada dur.

Bunun yapılmasının amacı Anlaşılabilirliği arttırmak ve Aşırı Öğrenmeyi engellemektir.



5. **Görsel Model:** Tree Viewer widget'ı ile Karar Ağacı'nın hangi kriterlere göre (örneğin: Fiber internet mi, Sözleşme süresi mi?) karar verdiği görselleştirildi.



Tree Viewer Analizi ve Yorumlama

Bu ağaçta **mavi** renkli kutular "Kalan" (No), **kırmızı/pembe** renkli kutular ise "Giden" (Yes) müşterileri temsil eder. En sağdaki pembe kutu bizim hedefimiz.

Riskli Profil Durumu:


1. **Sözleşme Tipi (Contract):** Ağaç en tepede veriyi ikiye bölmüş. Sağ tarafa, yani **"Month-to-month"** (Aylık sözleşme) dalına bakıyoruz. Risk burada başlıyor.
2. **İnternet Servisi (Internet):** Aylık sözleşmesi olanlar içinde tekrar bir ayırım yapılmış. Sağdaki dal olan **"Fiber optic"** yolunda renk burada daha da pembeleşiyor.
3. **Müşteri Sadakati (Tenure):** Fiber interneti ve aylık sözleşmesi olanlar içinde, şirkette kalma süresi **15 ay ve daha kısa** olanlar.

Tree Viewer Analizi Sonucunda En Riskli Müşteri Profili: Karar ağacı modeline göre şirket için en yüksek kayıp (churn) riski taşıyan grup; **aylık sözleşme (Month-to-month)** kullanan, **fiber optik** internet hizmeti alan ve şirketteki kıdemi **15 ay veya daha az** olan müşterilerdir.

Görselde bu profilin bulunduğu yaprak düğümde (leaf node) **Churn=Yes** oranının **%69** (en yüksek kırmızı yoğunluk) olduğu görülmektedir. Bu durum, yeni gelen ve esnek sözleşme ile yüksek maliyetli fiber hizmeti alan kitlenin sadakat oranının en düşük olduğunu kanıtlamaktadır.

Teslim Edilecekler:

- 1. Tamamlanmış Orange Workflow *.ows proje dosyası.



- 2. Üç modelin başarı oranlarını içeren karşılaştırma tablosu.


Model	AUC	CA (Doğruluk)	F1 Skoru	Precision	Recall	MCC
Logistic Regression	0.843	0.812	0.805	0.802	0.812	0.463
Tree	0.819	0.801	0.774	0.787	0.801	0.387
Random Forest	0.796	0.786	0.778	0.774	0.786	0.387

En Yüksek Başarı: Logistic Regression modeli, %**81.2** Classification Accuracy (CA) ve **0.843** AUC değeri ile tüm rakiplerini geride bırakmıştır.

Ayırt Edicilik: AUC değerinin 0.80'in üzerinde olması (0.843), modelin ayrılacak müşteriyi (Churn) kalacak olandan ayırma konusunda "**Çok İyi**" seviyede olduğunu kanıtlar.

İstikrar: Modelin Precision (0.802) ve Recall (0.812) değerlerinin birbirine yakın olması, tahminlerin dengeli ve güvenilir olduğunu gösterir.

- 3. Tree Viewer çıktısına bakarak: "Şirket için en riskli müşteri profili nedir?" sorusunun cevabı.



Bu çıktıya bakarak, **Şirket İçin En Riskli Müşteri Profili:** Yapılan Karar Ağacı (Tree Viewer) analizi sonucunda, şirketi terk etme (Churn) olasılığı en yüksek olan müşteri grubu şu özelliklere sahiptir:

- **Sözleşme Türü:** Aylık (Month-to-month)
- **İnternet Hizmeti:** Fiber Optik
- **Şirket Kıdemi (Tenure):** 15 ay ve daha kısa süreli müşteriler.

Analiz Notu: Görselde bu profilin bulunduğu "yaprak düğüm" (leaf node) incelendiğinde, bu gruptaki müşterilerin **%69'unun** (Yes: 69.0%) ayrılma eğiliminde olduğu görülmektedir. Bu, ağaçtaki en yüksek riskli kümedir.

Aylık sözleşme müşteriye her an bırakma esnekliği tanıyor, fiber optik ise genellikle daha yüksek fatura demek. Yeni müşteriler (düşük tenure) henüz sadakat bağı kurmadığı için bu iki faktör birleşince risk maksimize oluyor.